



UNIVERSITAT  
POLITÈCNICA  
DE VALÈNCIA

# Cuaderno de trabajo

## Clustering: algoritmo C-medias

Albert Sanchis

*DSIC*

Departamento de Sistemas  
Informáticos y Computación

# Objetivos formativos

- Aplicar el algoritmo  $C$ -medias de Duda y Hart

# Algoritmo $C$ -medias de Duda y Hart [1]

**Algorithm**  $C$ -means

**Input:**  $X; C; \Pi = \{X_1, \dots, X_C\};$

**Output:**  $\Pi^* = \{X_1, \dots, X_C\}; \mathbf{m}_1, \dots, \mathbf{m}_C; J$

**for**  $c = 1$  **to**  $C$  **do**  $\mathbf{m}_c = \frac{1}{n_c} \sum_{x \in X_c} x$  **endfor**

**repeat**

*transfers* = false

**forall**  $x \in X$  (let  $i : x \in X_i$ ) **do**

**if**  $n_i > 1$  **then**

$$j^* = \arg \min_{j \neq i} \frac{n_j}{n_j + 1} \|x - \mathbf{m}_j\|^2$$

$$\Delta J = \frac{n_{j^*}}{n_{j^*} + 1} \|x - \mathbf{m}_{j^*}\|^2 - \frac{n_i}{n_i - 1} \|x - \mathbf{m}_i\|^2$$

**if**  $\Delta J < 0$  **then**

*transfers* = true

$$\mathbf{m}_i = \mathbf{m}_i - \frac{x - \mathbf{m}_i}{n_i - 1} \quad \mathbf{m}_{j^*} = \mathbf{m}_{j^*} + \frac{x - \mathbf{m}_{j^*}}{n_{j^*} + 1}$$

$$X_i = X_i - \{x\} \quad X_{j^*} = X_{j^*} + \{x\}$$

$$J = J + \Delta J$$

**endif**

**endif**

**endforall**

**until**  $\neg \textit{transfers}$

# Algoritmo $C$ -medias de Duda y Hart

- **Entrada:** una partición inicial,  $\Pi = \{X_1, \dots, X_C\}$
- **Salida:** una partición optimizada,  $\Pi^* = \{X_1, \dots, X_C\}$
- **Método:**

Calcular medias y  $J$

**repetir**

**para todo** dato  $x$

Sea  $i$  el clúster en el que se encuentra  $x$

Hallar un  $j^* \neq i$  que minimice  $\Delta J$  al transferir  $x$  de  $i$  a  $j^*$

Si  $\Delta J < 0$ , transferir  $x$  de  $i$  a  $j^*$  y actualizar medias y  $J$


**hasta** no encontrar transferencias provechosas

- **Cuestión 1:** Dados los siguientes 5 vectores bidimensionales:

$$\mathbf{x}_1 = \begin{pmatrix} 1 \\ 7 \end{pmatrix} \quad \mathbf{x}_2 = \begin{pmatrix} 4 \\ 2 \end{pmatrix} \quad \mathbf{x}_3 = \begin{pmatrix} 4 \\ 6 \end{pmatrix} \quad \mathbf{x}_4 = \begin{pmatrix} 8 \\ 2 \end{pmatrix} \quad \mathbf{x}_5 = \begin{pmatrix} 8 \\ 6 \end{pmatrix}$$

y la siguiente partición inicial en dos clústers:

$$\Pi = \{X_1 = \{\mathbf{x}_1, \mathbf{x}_2, \mathbf{x}_3\}, X_2 = \{\mathbf{x}_4, \mathbf{x}_5\}\}$$




¿Cuál es la partición  $\Pi^*$  resultante tras aplicar el algoritmo  $C$ -medias de Duda y Hart?

■ **Cuestión 2:** Dados los siguientes 6 vectores bidimensionales:

$$\mathbf{x}_1 = \begin{pmatrix} 2 \\ 10 \end{pmatrix} \mathbf{x}_2 = \begin{pmatrix} 8 \\ 4 \end{pmatrix} \mathbf{x}_3 = \begin{pmatrix} 5 \\ 8 \end{pmatrix} \mathbf{x}_4 = \begin{pmatrix} 7 \\ 5 \end{pmatrix} \mathbf{x}_5 = \begin{pmatrix} 6 \\ 4 \end{pmatrix} \mathbf{x}_6 = \begin{pmatrix} 4 \\ 9 \end{pmatrix}$$

y la siguiente partición inicial en dos clústers:

$$\Pi = \{X_1 = \{\mathbf{x}_1\}, X_2 = \{\mathbf{x}_2, \mathbf{x}_3, \mathbf{x}_4, \mathbf{x}_5, \mathbf{x}_6\}\}$$



¿Cuál es la partición  $\Pi^*$  resultante tras aplicar el algoritmo  $C$ -medias de Duda y Hart?

# Referencias

- [1] R. O. Duda and P. E. Hart. *Pattern Classification and Scene Analysis*. Wiley, 1973.