

Bloque 2

Aprendizaje Automático

Práctica 2:

Sesión 2

Aplicación del algoritmo del Perceptron a tareas de clasificación

DOCENCIA VIRTUAL



Responsable del Tratamiento: Universitat Politècnica de València (UPV)

Finalidad: Prestación del servicio público de educación superior en base al interés público de la UPV (Art. 6.1.e del RGPD).

Ejercicio de derechos y segunda capa informativa: Podrán ejercer los derechos reconocidos en el RGPD y la LOPDGDD de acceso, rectificación, oposición, supresión, etc., escribiendo al correo dpd@upv.es.

Para obtener más información sobre el tratamiento de sus datos puede visitar el siguiente enlace: <https://www.upv.es/contenidos/DPD>.

Propiedad Intelectual: Uso exclusivo en el entorno del aula virtual.

Queda prohibida la difusión, distribución o divulgación de la grabación de las clases y particularmente su compartición en redes sociales o servicios dedicados a compartir apuntes.

La infracción de esta prohibición puede generar responsabilidad disciplinaria, administrativa y/o civil.

Sesiones de la práctica 2

Sesión 1:

- Familiarizarse con el entorno de trabajo (Google Colab)
- Analizar conjuntos de datos (datasets): **iris**, **digits**, **olivetti**, **openml**

Sesión 2:

- Aplicación del algoritmo del Perceptron a tareas de clasificación: dataset **iris**.
- **Ejercicio:** Aplicar Perceptrón a **digits** y **olivetti**

Sesión 3:

- Aplicación de Regresión Logística a tareas de clasificación: dataset **iris**.

Ejemplo de examen:

- Aplicación de Perceptrón y Regresión Logística a un dataset de OpenML.

Sesión 4 (**examen**):

- Se pedirá la aplicación de Regresión Logística para una tarea diferente de OpenML
- Hay que subir también la **solución del Ejercicio**


Sesión 2: Aplicación del algoritmo del Perceptron

- Un clasificador lineal toma una decisión de clasificación basándose en una **combinación lineal de las características de entrada**.
- Una **función discriminante lineal** se utiliza para dividir el espacio de características en regiones de decisión, clasificando los puntos de acuerdo con sus valores.

$$g_c(x) = w_c^T x + w_{c0}$$

$$g_c(x) = w_{c1}x_1 + w_{c2}x_2 + \dots + w_{cn}x_n + w_{c0}$$


Donde x son los valores de una muestra, w son los pesos incluido el término independiente.



Sesión 2: Aplicación del algoritmo del Perceptron

Ejemplo en el dataset Iris

- Tenemos la muestra:



x_1 : Long. sépalo	x_2 : Ancho sépalo	x_3 : Long. pétalo	x_4 : Ancho pétalo
5.1	3.5	1.4	0.2

- La función lineal tiene la forma:

$$g_c(x) = w_{c0} + w_{c1}x_1 + w_{c2}x_2 + \dots + w_{cn}x_n$$

- Suponiendo los siguientes pesos:

w_{c0}	w_{c1}	w_{c2}	w_{c3}	w_{c4}
-2.0	0.6	-0.3	1.2	0.5

- El cálculo es: $g_c(x) = (-2.0)(1) + (0.6)(5.1) + (-0.3)(3.5) + (1.2)(1.4) + (0.5)(0.2)$

$$g_c(x) = -2.0 + 3.06 - 1.05 + 1.68 + 0.1 = 1.79$$

Sesión 2: Aplicación del algoritmo del Perceptron

Clasificador lineal

Dado un conjunto de funciones lineales $g_c(x)$ para cada clase $c \in \{1, 2, \dots, C\}$, donde:

$$g_c(x) = w_c^T x + w_{c0}$$

El clasificador asigna una entrada x a la clase c tal que:

$$\hat{c} = \arg \max_c g_c(x)$$

El clasificador selecciona la clase cuya función discriminante $g_c(x)$ tiene el valor más alto.

Sesión 2: Aplicación del algoritmo del Perceptron

- Ejemplo Iris

Característica	Iris-setosa	Iris-versicolor	Iris-virginica
Término Independiente	-1.5	0.5	0.8
x_1 (Sepal Length)	0.5	-0.3	0.2
x_2 (Sepal Width)	-0.2	0.7	0.4
x_3 (Petal Length)	0.8	0.6	-0.5
x_4 (Petal Width)	0.3	0.2	0.9



$$W = \begin{matrix} & g_0(x) & g_1(x) & g_2(x) \\ \begin{bmatrix} -1.5 & 0.5 & 0.8 \\ 0.5 & -0.3 & 0.2 \\ -0.2 & 0.7 & 0.4 \\ 0.8 & 0.6 & -0.5 \\ 0.3 & 0.2 & 0.9 \end{bmatrix} \end{matrix}$$

Un clasificador al final es una matriz de pesos

Sesión 2: Aplicación del algoritmo del Perceptron

¿Cómo obtener la matriz? → ¿Como aprendemos los pesos? → Algoritmo Perceptron

Entrada: $\{(\mathbf{x}_n, c_n)\}_{n=1}^N$, $\{\mathbf{w}_c\}_{c=1}^C$, $\alpha \in \mathbb{R}^{>0}$ y $b \in \mathbb{R}$

Salida: $\{\mathbf{w}_c\}^* = \arg \min_{\{\mathbf{w}_c\}} \sum_n \left[\max_{c \neq c_n} \mathbf{w}_c^t \mathbf{x}_n + b > \mathbf{w}_{c_n}^t \mathbf{x}_n \right]$

Método: $[P] = \begin{cases} 1 & \text{si } P = \text{verdadero} \\ 0 & \text{si } P = \text{falso} \end{cases}$

repetir

para todo dato \mathbf{x}_n

$err = \text{falso}$

para toda clase c distinta de c_n

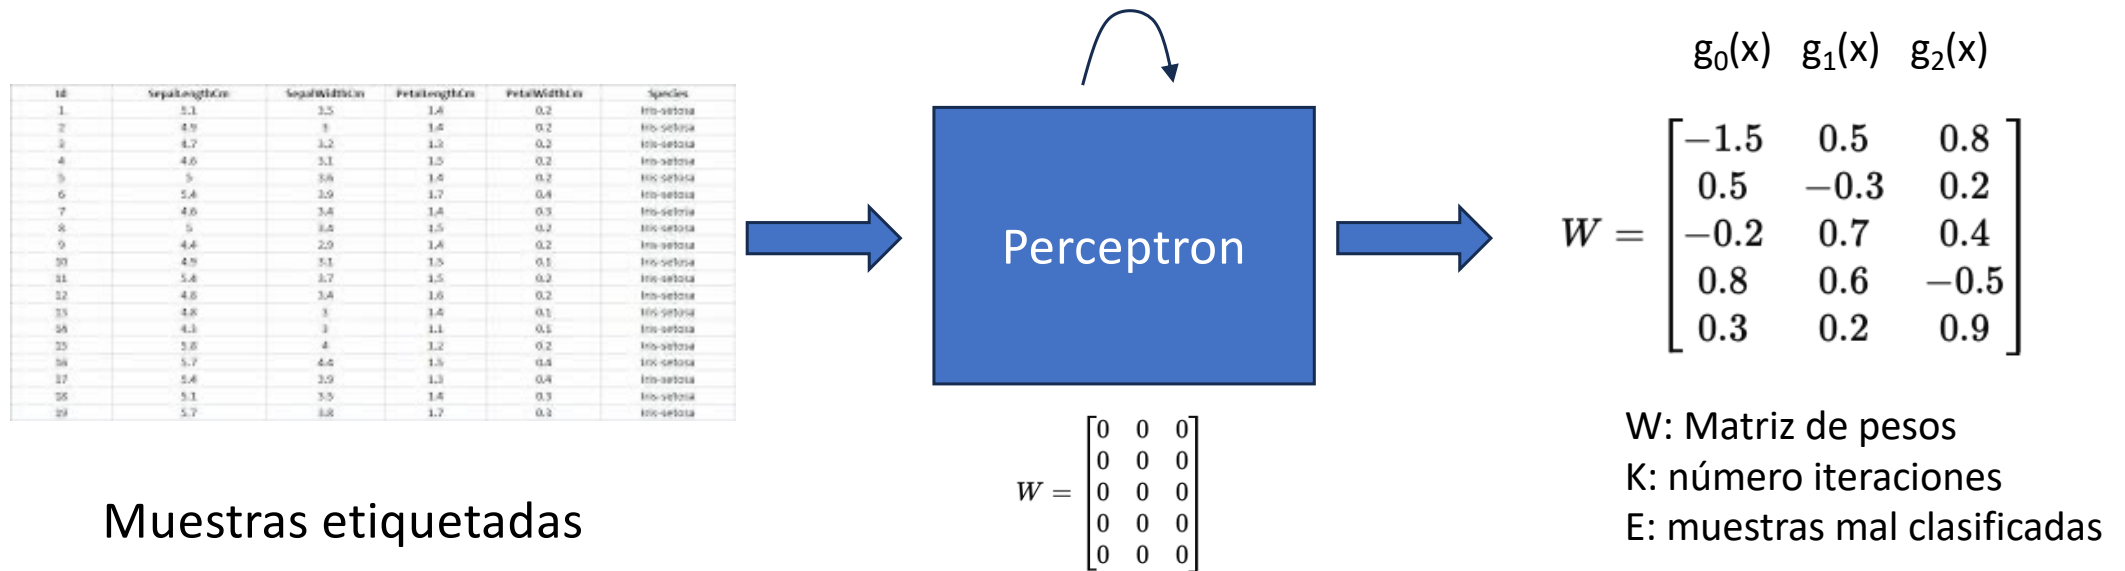
si $\mathbf{w}_c^t \mathbf{x}_n + b > \mathbf{w}_{c_n}^t \mathbf{x}_n$: $\mathbf{w}_c = \mathbf{w}_c - \alpha \cdot \mathbf{x}_n$; $err = \text{verdadero}$

si err : $\mathbf{w}_{c_n} = \mathbf{w}_{c_n} + \alpha \cdot \mathbf{x}_n$

hasta que no queden muestras mal clasificadas

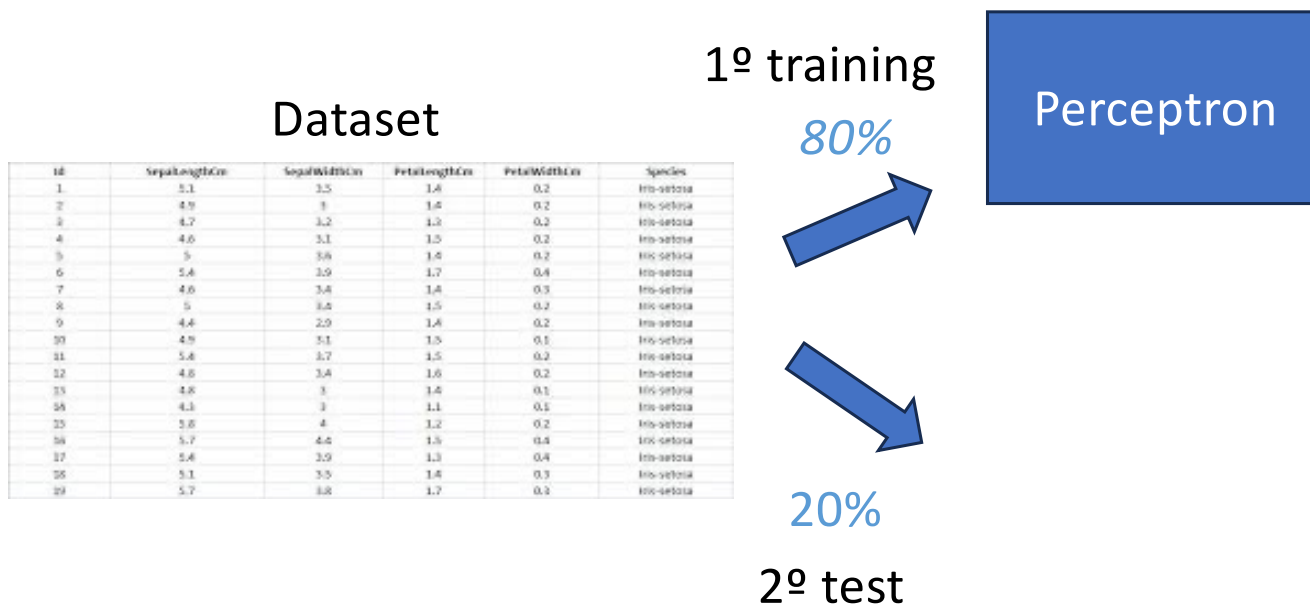
(o se llegue a un máximo de iteraciones prefijado)

Sesión 2: Aplicación del algoritmo del Perceptron



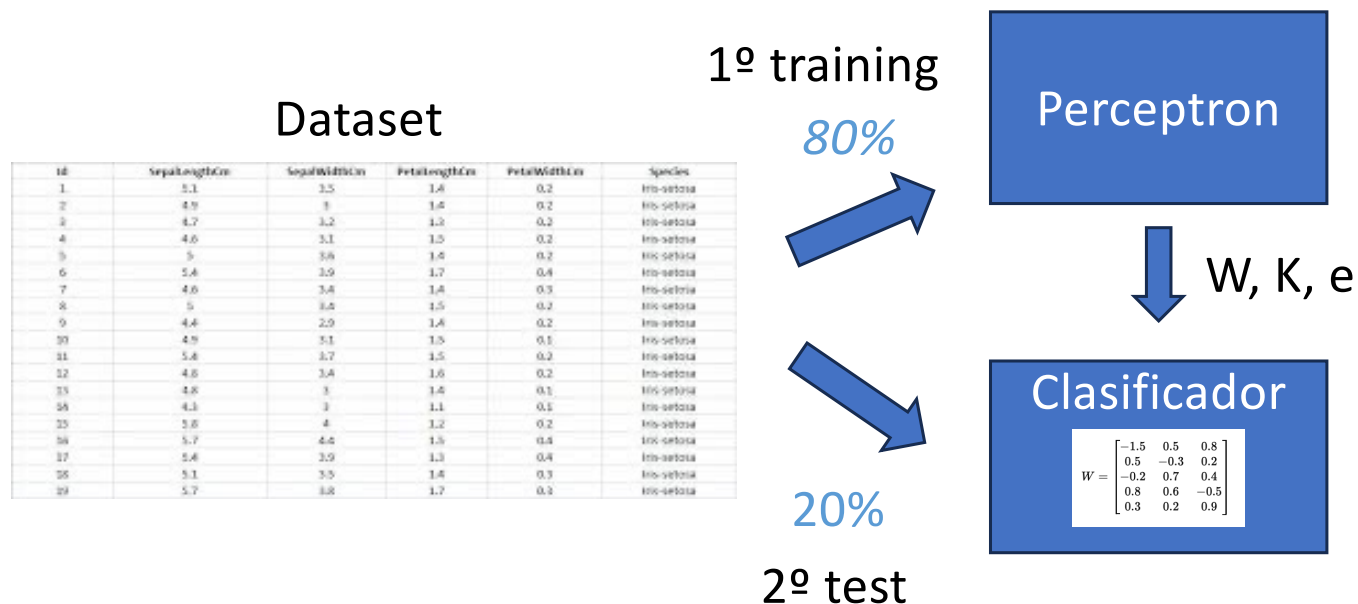
Sesión 2: Aplicación del algoritmo del Perceptron

- **Cálculo del error:** dividir el dataset en dos subconjuntos, uno para **entrenamiento (training)** y otro para **pruebas (test)**



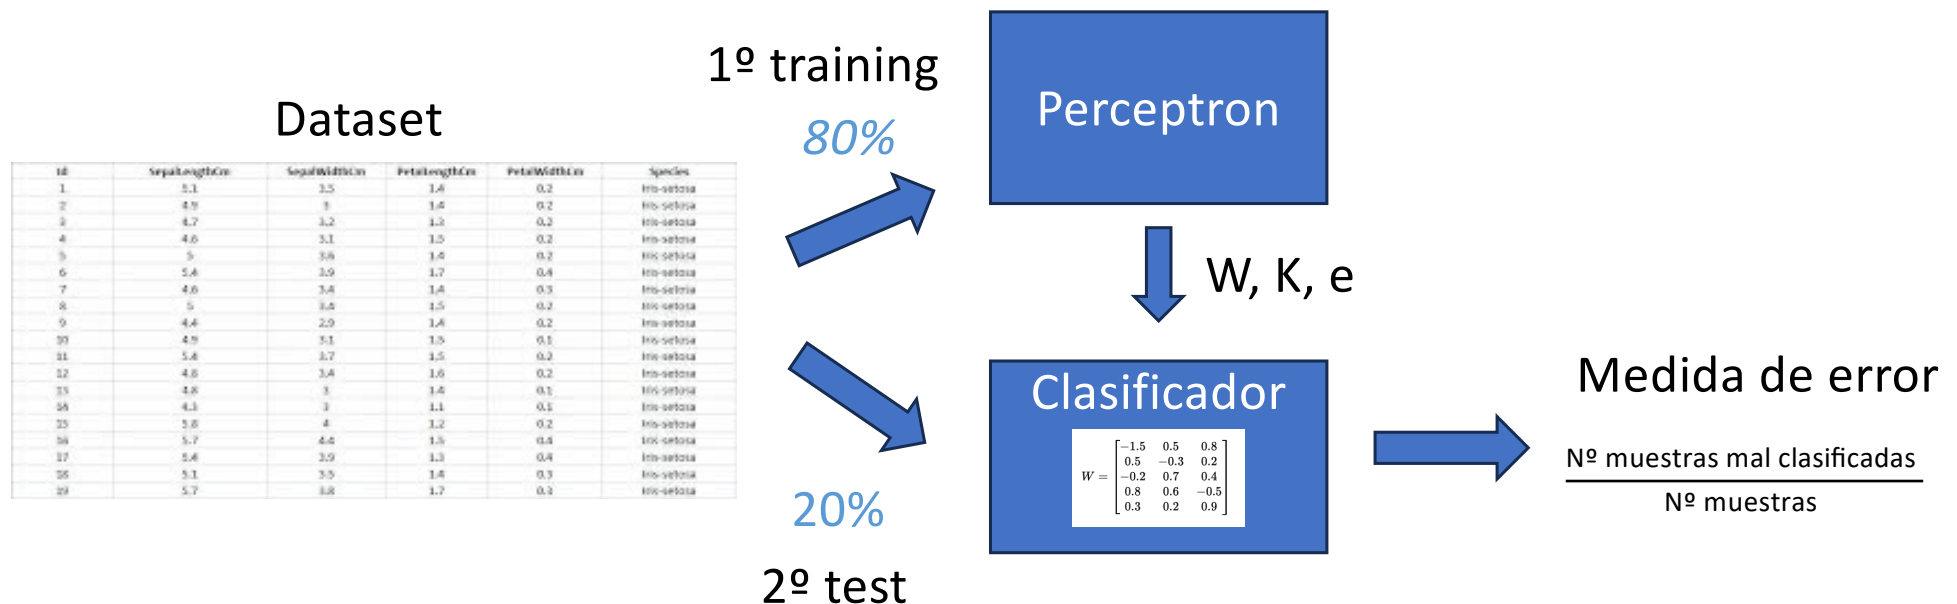
Sesión 2: Aplicación del algoritmo del Perceptron

- **Cálculo del error:** dividir el dataset en dos subconjuntos, uno para **entrenamiento (training)** y otro para **pruebas (test)**



Sesión 2: Aplicación del algoritmo del Perceptron

- **Cálculo del error:** dividir el dataset en dos subconjuntos, uno para **entrenamiento (training)** y otro para **pruebas (test)**



Sesión 2: Aplicación del algoritmo del Perceptron

Ajuste del modelo

- **α : tasa de aprendizaje (Learning Rate):** Es un escalar que determina cuánto se ajustan los pesos durante el proceso de aprendizaje.
 - Si α es demasiado grande, el algoritmo puede oscilar o divergir. Si es demasiado pequeño, el aprendizaje será lento.
 - Se puede probar con diferentes α : (.01, .1, 10, 100)
- **b: margen**
 - Es un parámetro adicional que permite ajustar las fronteras de decisión
 - Se puede probar con diferentes b: (.0, .01, .1, 10, 100)

Sesión 2: Aplicación del algoritmo del Perceptron

Probar iris.ipynb

Ejercicio: Aplicar Perceptrón a digits y Olivetti. (entregar el dia del examen)