

T1.1 Razonamiento probabilístico: representación e inferencia

Índice

1. El problema de la calificación
2. Representación probabilística
3. Inferencia probabilística
4. Independencia
5. Teorema de Bayes

1 El problema de la calificación

Problema de la calificación: imposibilidad práctica de conocer y comprobar todas las **calificaciones** (condiciones) que habría que garantizar para asegurar el cumplimiento de una acción

- Ejemplo: salir al aeropuerto 90 minutos antes del vuelo me permite llegar a tiempo SI no hay atascos Y no hay pinchazos Y ...
- Ejemplo: un bote nos permite cruzar un río SI es un bote de remo Y tiene remos y escálamos Y no están rotos Y encajan Y ...

Incertidumbre: los sistemas inteligentes actuales incluyen la **incertidumbre** como parte del conocimiento y la representan mediante **probabilidades** asociadas a los sucesos (proposiciones) de interés

2 Representación probabilística

Distribución de probabilidad conjunta: de las variables aleatorias de interés para representar el conocimiento probabilístico

Ejemplo del dentista: conocimiento para diagnosticar caries

Variables aleatorias de interés:

Dolor: $D \in \{0, 1\}$
Caries: $C \in \{0, 1\}$
Hueco: $H \in \{0, 1\}$

Representación: tabla a la derecha con

$P(D = d, C = c, H = h)$ para todo $d, c, h \in \{0, 1\}$

d	c	h	P
0	0	0	0.576
0	0	1	0.008
0	1	0	0.144
0	1	1	0.072
1	0	0	0.064
1	0	1	0.012
1	1	0	0.016
1	1	1	0.108

Handwritten notes: $1000 \rightarrow 576$ (next to the first row); $d=$ (next to the first column); h (above the third column); red boxes around (0,0,1), (0,1,1), (1,0,1), and (1,1,1); blue circles around (0,1,1) and (1,1,1); blue lines under the probabilities 0.072 and 0.108.

3 Inferencia probabilística

$$P(y, x, z)$$

Reglas suma y producto: reglas básicas para calcular la probabilidad de cualquier **suceso (proposición)** de interés a partir de la distribución conjunta

$$P(x) = \sum_y P(x, y)$$

y

$$P(x, y) = P(x) P(y | x) = P(y) \cdot P(x | y)$$

$$P(x, y, z) = P(x | y, z) \cdot P(y, z) = P(x | y, z) \cdot P(y | z) \cdot P(z) = P(x | y, z) \cdot P(z, y) \cdot P(y)$$

Observación importante: en general no es necesario conocer la tabla completa de probabilidades conjuntas para calcular la probabilidad de un suceso dado mediante las reglas suma y producto

Ejemplo del dentista: cálculo de la probabilidad de observar...

• Caries y hueco (a la vez): $P(c = 1, h = 1) = \sum_{d=0,1} P(d, c = 1, h = 1) = \underline{0.180}$

• Hueco: $P(h = 1) = \sum_{d=0,1} \sum_{c=0,1} P(d, c, h = 1) = \underline{0.200} = P(d=0, c=0, h=1) + P(d=0, c=1, h=1) + P(d=1, c=0, h=1) + P(d=1, c=1, h=1)$

• Caries después de observar hueco: $P(c = 1 | h = 1) = \frac{P(c = 1, h = 1)}{P(h = 1)} = \frac{0.180}{0.200} = 0.900$

```
In [1]: import numpy as np
T = np.array([[0,0,0,.576], [0,0,1,.008], [0,1,0,.144], [0,1,1,.072],
              [1,0,0,.064], [1,0,1,.012], [1,1,0,.016], [1,1,1,.108]])
Pc1b1 = np.sum(T[(T[:,1]==1) & (T[:,2]==1)], -1)
Pb1 = np.sum(T[T[:,2]==1, -1])
Pc1Db1 = Pc1b1/Pb1
print(f"Pc1b1 = {Pc1b1:.3f} Pb1 = {Pb1:.3f} Pc1Db1 = {Pc1Db1:.3f}")
```

Pc1b1 = 0.180 Pb1 = 0.200 Pc1Db1 = 0.900

$$P(c=1, h=1) = P(c=1 | h=1) \cdot P(h=1)$$

4 Independencia

Variables independientes: dos variables x y y son **independientes** si

$$\underline{P(x, y)} = \underline{P(x)} \underline{P(y)} \quad \text{o} \quad \underline{P(x | y)} = \underline{P(x)} \quad \text{o} \quad \underline{P(y | x)} = \underline{P(y)}$$

Conocimiento experto: la independencia puede establecerse por conocimiento experto y conveniencia

Ejemplo del dentista:

- Consideramos una nueva variable con el tiempo que hace cuando el paciente visita el dentista

$$T \in \{\text{sol, nubes, lluvia, nieve}\}$$

- Asumimos que las tres variables que ya teníamos son independientes del tiempo que hace

$$\boxed{P(d, c, h, t)} = \underline{P(t)} \underline{P(d, c, h)} \cancel{=} \underline{P(t)} \underline{P(d, c, h)}$$

- Así reducimos el número de probabilidades a almacenar: 32 vs 4 + 8

5 Teorema de Bayes

Teorema de Bayes: permite actualizar nuestro conocimiento sobre una hipótesis y después de observar una nueva evidencia x

$$P(x, y) = P(y|x) \cdot P(x)$$

$$P(y|x) = \frac{P(x, y)}{P(x)} = P(y) \frac{P(x|y)}{P(x)}$$

- De otra manera: $P(y|x)$ es la probabilidad de que se produzca el efecto y después de observar que se ha producido la causa x

Ejemplo del dentista:

- Sabemos que la probabilidad de caries es: $P(c = 1) = 0.34$
- Sabemos que la probabilidad de dolor es: $P(d = 1) = 0.20$
- Sabemos que la probabilidad de dolor después de observar caries es: $P(d = 1 | c = 1) = 0.36$
- ¿Cuál es la probabilidad de caries después de observar dolor, $P(c = 1 | d = 1)$?

$$\underline{P(c = 1 | d = 1)} = \underline{P(c = 1)} \frac{P(d = 1 | c = 1)}{P(d = 1)} = \underline{0.34} \frac{0.36}{\underline{0.20}} = \underline{0.61}$$

```
In [3]: Pc1 = 0.34; Pd1 = 0.20; Pd1c1 = 0.36; Pc1Dd1 = Pc1 * Pd1c1 / Pb1; print(f"Pc1Dd1 = {Pc1Dd1:.2f}")
Pc1Dd1 = 0.61
```

$$P(c=1|d=1) = \frac{P(c=1, d=1)}{P(d=1)} = \frac{P(d=1|c=1) \cdot P(c=1)}{P(d=1)}$$

$$P(c=1, d=1) = P(c=1|d=1) \cdot P(d=1)$$

Ejercicios T1.1 Razonamiento probabilístico

2023_01_26_Cuestión 1: Dada la siguiente tabla de probabilidades conjuntas de tres variables de interés:

A	0	0	0	0	1	1	1	1
B	0	0	1	1	0	0	1	1
C	0	1	0	1	0	1	0	1
$P(A, B, C)$	0.093	0.100	0.133	0.163	0.157	0.150	0.117	0.087

Cual es el valor de $P(A = 1, B = 1 | C = 1)$?

1. $P(A = 1, B = 1 | C = 1) \leq 0.25$
2. $0.25 < P(A = 1, B = 1 | C = 1) \leq 0.50$
3. $0.50 < P(A = 1, B = 1 | C = 1) \leq 0.75$
4. $0.75 < P(A = 1, B = 1 | C = 1)$

$$P(A=1, B=1 | C=1) = \frac{P(A=1, B=1, C=1)}{P(C=1)} = \frac{0.087}{0.5} = 0.174$$

$$P(C=1) = \sum_{A \in \{0,1\}} \sum_{B \in \{0,1\}} P(A, B, C=1) = P(A=0, B=0, C=1) + P(A=0, B=1, C=1) + P(A=1, B=0, C=1) + P(A=1, B=1, C=1) = 0.5$$

$$P(A=1, B=1, C=1) = P(A=1, B=1 | C=1) \cdot P(C=1)$$

Solución: la 1; $P(A = 1, B = 1 \mid C = 1) = 0.174$

```
In [1]: PA1B1C1 = 0.087; PC1 = 0.1 + 0.163 + 0.15 + 0.087; PA1B1_C1 = PA1B1C1 / PC1; print(PA1B1_C1)
0.174
```


2023_01_17_Cuestión 1: Supón que tenemos dos cajas con 40 naranjas en la primera y 80 en la segunda. La primera caja contiene 9 naranjas Navelina y 31 Caracara. La segunda caja contiene tres veces más naranjas Navelina que Caracara. Ahora supón que se escoge una caja al azar, y después una naranja al azar de la caja escogida. Si la naranja escogida es Navelina, la probabilidad P de que proceda de la primera caja es:

1. $0/4 \leq P < 1/4$.

2. $1/4 \leq P < 2/4$.

3. $2/4 \leq P < 3/4$.

4. $3/4 \leq P \leq 4/4$.

$$C = \{1, 2\}$$

$$O = \{N, C\}$$

$$P(C=1) = \frac{40}{40+80} = \frac{1}{3} = 0.33$$

$$P(C=2) = \frac{80}{40+80} = \frac{2}{3}$$

$$P(O=N|C=1) = \frac{9}{40} \quad P(O=N|C=2) = \frac{3}{4}$$

$$P(O=C|C=1) = \frac{31}{40} \quad P(O=C|C=2) = \frac{1}{4}$$

$$3 \cdot x + x = 1$$

$$P(C=1|O=N) = \frac{P(O=N|C=1) \cdot P(C=1)}{P(O=N)}$$

$$\underline{\underline{P(O=N)}} = \sum_{C \in \{1,2\}} P(C, O=N) = \sum_{C \in \{1,2\}} P(O=N|C) \cdot P(C) = \frac{P(O=N|C=1) \cdot P(C=1) + P(O=N|C=2) \cdot P(C=2)}{}$$

Solución:

$$\begin{aligned} P = P(C = 1 \mid T = N) &= \frac{P(C = 1)P(T = N \mid C = 1)}{P(C = 1)P(T = N \mid C = 1) + P(C = 2)P(T = N \mid C = 2)} \\ &= \frac{1/2 \cdot 9/40}{1/2 \cdot 9/40 + 1/2 \cdot 3/4} = \frac{9}{9 + 30} = 0.23 \end{aligned}$$

2022_01_27_Cuestión 4: Dada la siguiente tabla de frecuencias conjuntas de tres variables de interés:

A	0	0	0	0	1	1	1	1
B	0	0	1	1	0	0	1	1
C	0	1	0	1	0	1	0	1
$N(A, B, C)$	124	28	227	175	126	222	23	75

Cúal és el valor de $P(A = 1 \mid B = 1, C = 0)$?

1. 0.023
2. 0.250
3. 0.092
4. 0.446

Solución: la 3.

2022_01_13_Cuestión 7: Sea un problema de razonamiento probabilístico sobre desplazamientos por carretera, con las variables aleatorias de interés:

- Climatología (C): {claro(CLA), nublado (NUB), lluvia (LLU)}
- Luminosidad (L): {día (DÍA), noche (NOCHE)}
- Seguridad (S): {seguro (SEG), accidente (ACC)}

La probabilidad conjunta de las tres variables viene dada en la tabla:

$P(S, L, C)$	DÍA			NOCHE		
	CLA	NUB	LLU	CLA	NUB	LLU
SEG	0.27	0.23	0.07	0.16	0.07	0.06
ACC	0.02	0.01	0.02	0.02	0.03	0.04

La probabilidad condicional $P(S = \text{ACC} \mid L = \text{DÍA}, C = \text{NUB})$ es:

1. 0.042
2. 0.010
3. 0.240
4. 0.140

Solución: la 1.

T1.2 Variables continuas y regla de Bayes

Índice

1. Variables continuas
2. Teorema de Bayes en el caso continuo
3. La regla de decisión de Bayes
4. Clasificadores generativos y discriminativos

1 Variables continuas


Función de densidad de probabilidad: caracterización usual de las variables continuas para la representación de conocimiento probabilístico

$$p(x) \geq 0 \quad \text{para todo } x \quad \text{y} \quad \int p(x) dx = 1$$

La densidad normal: $p(x) \sim \mathcal{N}(\mu, \sigma^2)$


$$p(x) = \frac{1}{\sqrt{2\pi}\sigma} \exp\left(-\frac{(x-\mu)^2}{2\sigma^2}\right)$$

$$P(x \in [\mu \pm 1.96\sigma]) = 0.95$$



Ejemplo: densidades normales con $\mu = 0$ y $\sigma^2 = 0.5, 1, 2$

```
In [2]: import numpy as np; from scipy.stats import norm; import matplotlib.pyplot as plt
x = np.linspace(-3, 3, 200)
plt.figure(figsize=(5, 2.5))
plt.plot(x, norm.pdf(x, 0, np.sqrt(0.5)), x, norm.pdf(x, 0, 1), x, norm.pdf(x, 0, np.sqrt(2)));
```




2 Teorema de Bayes en el caso continuo

Teorema de Bayes en el caso continuo: probabilidad de una hipótesis y después de observar una evidencia (nueva) x

$$P(y | x) = P(y) \frac{p(x | y)}{p(x)}$$

Ejemplo: x = resultado de un test de saliva para el diagnóstico de caries

- Sin caries, $c = 0$, $p(x | c = 0) \sim \mathcal{N}(\mu = 0, \sigma^2 = 1)$
- Con caries, $c = 1$, $p(x | c = 1) \sim \mathcal{N}(\mu = 2, \sigma^2 = 0.5)$
- Sabemos que la probabilidad (a priori) de caries es: $P(c = 1) = 0.34$
- Si el test da $x = 2$, cuál es la probabilidad (a posteriori) de caries?



$$P(c = 1 | x = 2) = P(c = 1) \frac{p(x = 2 | c = 1)}{p(x = 2)} = 0.340 \frac{0.564}{0.307} = 0.843$$

- Observa que primero había que encontrar la (densidad de) probabilidad (a priori) de test $x = 2$:

$$\begin{aligned} p(x = 2) &= P(c = 0)p(x = 2 | c = 0) + P(c = 1)p(x = 2 | c = 1) \\ &= (1 - 0.34) \cdot 0.054 + 0.34 \cdot 0.564 = 0.227 \end{aligned}$$

```
In [3]: Pc1 = 0.34; px2Dc0 = norm.pdf(2, 0, 1); px2Dc1 = norm.pdf(2, 2, np.sqrt(0.5))
px2 = (1-Pc1) * px2Dc0 + Pc1 * px2Dc1; Pc1Dx2 = Pc1 * px2Dc1 / px2
print(f"px2Dc0 = {px2Dc0:.3f}  px2Dc1 = {px2Dc1:.3f}  px2 = {px2:.3f}  Pc1Dx2 = {Pc1Dx2:.3f}")

px2Dc0 = 0.054  px2Dc1 = 0.564  px2 = 0.227  Pc1Dx2 = 0.843
```

3 La regla de decisión de Bayes

Regla de decisión de Bayes: predice una hipótesis después de observar una evidencia x mediante la elección, entre un conjunto de hipótesis posibles \mathcal{C} , de una hipótesis de máxima **probabilidad a posteriori** (de la observación de la evidencia)

6 ó 9

$$c^*(x) = \operatorname{argmax}_{c \in \mathcal{C}} P(c | x)$$

imagen

$$P(c=6 | x=\boxed{6}) = 0.9 \quad \underline{c^*(x)=6}$$

$$P(c=9 | x=\boxed{6}) = 0.1$$

Probabilidad de error: es decir, probabilidad de que la hipótesis predicha sea distinta de la realmente producida

$$\rightarrow P(\text{error} | x) = 1 - P(\underline{c^*(x)} | x)$$

$$c^*(x)=6 \rightarrow P(\text{error} | x) = 1 - 0.9 = 0.1$$

$$c^*(x)=9 \rightarrow P(\text{error} | x) = 1 - 0.1 = 0.9$$

Optimalidad de la regla de Bayes: ninguna otra elección mejoraría esta probabilidad de error!

Ejemplo del dentista:

$$\underline{c^*(x=2)} = \operatorname{argmax}_c \begin{pmatrix} P(c=0 | x=2) = 0.116 \\ P(c=1 | x=2) = 0.884 \end{pmatrix} = 1$$

Regla de Bayes en función de probabilidades a priori y (densidades) condicionales de las clases: en lugar (de arg-)maximizar $P(c | x)$ en c , lo hacemos en función de $P(c) p(x | c)$ puesto que el resultado es el mismo

$$c^*(x) = \operatorname{argmax}_{c \in \mathcal{C}} P(c | x) = \operatorname{argmax}_{c \in \mathcal{C}} P(c) \frac{p(x | c)}{p(x)} = \operatorname{argmax}_{c \in \mathcal{C}} P(c) p(x | c)$$

Ejemplo del dentista:


$$c^*(x=2) = \operatorname{argmax}_c \begin{pmatrix} P(c=0) p(x=2 | c=0) = 0.036 \\ P(c=1) p(x=2 | c=1) = 0.271 \end{pmatrix} = 1$$

Ejercicios T1.2 Variables continuas y regla de Bayes

Problema: Considerad la clasificación de flores iris en setosa o no-setosa a partir de la longitud de pétalos, x . El estudio empírico siguiente muestra que las distribuciones de x para setosas y no-setosas pueden aproximarse con distribuciones normales de medias y desviaciones estándares:

$$p(x \mid c = \text{set}) \sim \mathcal{N}(\mu_{\text{set}} = 1.46, \sigma_{\text{set}} = 0.17) \quad \text{y} \quad p(x \mid c = \text{nos}) \sim \mathcal{N}(\mu_{\text{nos}} = 4.91, \sigma_{\text{nos}} = 0.82)$$

```
In [1]: import numpy as np; import matplotlib.pyplot as plt
from sklearn.datasets import load_iris; from scipy.stats import norm
iris = load_iris(); X = iris.data.astype(np.float16); y = iris.target.astype(np.uint)
x_set = np.squeeze(X[np.where(y==0), 2]); x_nos = np.squeeze(X[np.where(y!=0), 2])
fig, axs = plt.subplots(1, 2, figsize=(8, 2), sharey=True, tight_layout=True)
axs[0].hist(x_set, bins='auto', density=True, histtype='step')
x_set_range = np.arange(*axs[0].get_xlim(), .01)
x_set_mean = x_set.mean(); x_set_dev = np.sqrt(x_set.var())
axs[0].set_title(f'setosa: m={x_set_mean:.2f} dev={x_set_dev:.2f}')
axs[0].plot(x_set_range, norm.pdf(x_set_range, x_set_mean, x_set_dev))
axs[1].hist(x_nos, bins='auto', density=True, histtype='step')
x_nos_range = np.arange(*axs[1].get_xlim(), .01)
x_nos_mean = x_nos.mean(); x_nos_dev = np.sqrt(x_nos.var())
axs[1].set_title(f'no setosa: m={x_nos_mean:.2f} dev={x_nos_dev:.2f}')
axs[1].plot(x_nos_range, norm.pdf(x_nos_range, x_nos_mean, x_nos_dev));
```



Si las densidades normales estimadas son ciertas y la probabilidad a priori de setosa es $1/3$, ¿cuál es la probabilidad a posteriori de que una flor de longitud de pétalos 2 sea setosa?

Solución:

$$\begin{aligned} P(c = \text{set} \mid x = 2) &= \frac{P(c = \text{set}) p(x = 2 \mid c = \text{set})}{p(x = 2)} \\ &= \frac{P(c = \text{set}) p(x = 2 \mid c = \text{set})}{P(c = \text{set}) p(x = 2 \mid c = \text{set}) + P(c = \text{nos}) p(x = 2 \mid c = \text{nos})} \\ &= \frac{1/3 \cdot \mathcal{N}(x = 2 \mid \mu_{\text{set}} = 1.46, \sigma_{\text{set}} = 0.17)}{1/3 \cdot \mathcal{N}(x = 2 \mid \mu_{\text{set}} = 1.46, \sigma_{\text{set}} = 0.17) + 2/3 \cdot \mathcal{N}(x = 2 \mid \mu_{\text{nos}} = 4.91, \sigma_{\text{nos}} = 0.82)} \\ &= \frac{\frac{1}{0.17} \exp\left(-\frac{(2-1.46)^2}{2 \cdot 0.17^2}\right)}{\frac{1}{0.17} \exp\left(-\frac{(2-1.46)^2}{2 \cdot 0.17^2}\right) + \frac{2}{0.82} \exp\left(-\frac{(2-4.91)^2}{2 \cdot 0.82^2}\right)} = \frac{0.0379}{0.0379 + 0.0045} = 0.89 \end{aligned}$$