



UNIVERSITAT  
POLITÈCNICA  
DE VALÈNCIA

# Introducció a l'estimació de l'error en Reconeixement de Formes

Alfons Juan  
Albert Sanchis  
Jorge Civera

*DSIC*

Departament de Sistemes  
Informàtics i Computació

# Objectius formatius

- Calcular l'error teòric d'un classificador
- Calcular l'error de Bayes
- Estimar l'error d'un classificador per resubstitució
- Estimar l'error d'un classificador per *holdout* i afegir-hi un interval de confiança al 95%

# Índex

1	Error teòric d'un classificador	3
2	Error del classificador de Bayes	4
3	Estimació de l'error per resubstitució	5
4	Estimació de l'error per <i>holdout</i>	6

# 1 Error teòric d'un classificador

L'**error** (esperat) d'un classificador  $c(x)$ , per a tot  $x \in E$ , és:

$$\varepsilon = E(\varepsilon(c(x))) = \begin{cases} \sum_x P(x) \varepsilon(c(x)) & \text{si } E \text{ és discret} \\ \int p(x) \varepsilon(c(x)) dx & \text{si } E \text{ és continu} \end{cases}$$

on  $\varepsilon(c(x))$  és la probabilitat d'error de  $c(x)$  per a  $x$ :

$$\varepsilon(c(x)) = 1 - P(c = c(x) \mid x)$$

**Exemple (problema i classif.):**  $E = [0, 1]^2$ ,  $C = 2$ ,  $\eta_c(\mathbf{x}) \triangleq P(c \mid \mathbf{x})$

$x_1$	$x_2$	$\eta_1(\mathbf{x})$	$\eta_2(\mathbf{x})$	$P(\mathbf{x})$	$c(\mathbf{x})$	$\varepsilon(c(\mathbf{x}))$
0	0	1	0	1/2	1	0
0	1	3/4	1/4	1/4	1	1/4
1	0	1/4	3/4	1/4	1	3/4
1	1	0	1	0	2	0

$$\Rightarrow \varepsilon = \frac{1}{4} \cdot \frac{1}{4} + \frac{1}{4} \cdot \frac{3}{4} = \frac{1}{4}$$

## 2 Error del classificador de Bayes

El **classificador de Bayes** tria una classe de màxima probabilitat a posteriori:

$$c^*(x) = \arg \max_c P(c \mid x)$$

La seua probabilitat d'error per a un  $x$  qualsevol és mínima:

$$\varepsilon(c^*(x)) = 1 - P(c^*(x) \mid x) = 1 - \max_c P(c \mid x)$$

per la qual cosa també ho és el seu error, l'**error de Bayes**:

$$\varepsilon^* = E(\varepsilon(c^*(x))) = \begin{cases} \sum_x P(x) \varepsilon(c^*(x)) & \text{si } E \text{ és discret} \\ \int p(x) \varepsilon(c^*(x)) dx & \text{si } E \text{ és continu} \end{cases}$$

**Exemple:**  $\varepsilon^* = \frac{1}{8}$  (per al problema exemple)

### 3 Estimació de l'error per resubstitució

Siga  $c_N(x)$  un classificador après amb un conjunt de  $N$  mostres,  $S_N = \{(x_1, c_1), (x_2, c_2), \dots, (x_N, c_N)\}$ , i siga  $\varepsilon_N$  el seu error.

Anomenem estimador per **resubstitució** de  $\varepsilon_N$  a:

$$\hat{\varepsilon}_N^r = \frac{1}{N} \sum_{n=1}^N [c_N(x_n) \neq c_n] = \frac{\text{nombre d'errors}}{N}$$

És **optimista**, sobretot amb classificadors complexos i  $N$  menut.

**Exemple:**  $N = 4$  (per al problema exemple)

$x_1$	$x_2$	$\eta_1(\mathbf{x})$	$\eta_2(\mathbf{x})$	$P(\mathbf{x})$	$N_1(\mathbf{x})$	$N_2(\mathbf{x})$	$c_N(\mathbf{x})$
0	0	1	0	1/2	2	0	1
0	1	3/4	1/4	1/4	1	0	1
1	0	1/4	3/4	1/4	1	0	1
1	1	0	1	0	0	0	—

$$\Rightarrow \hat{\varepsilon}_N^r = \frac{0}{4}$$

## 4 Estimació de l'error per *holdout*

Siga  $S_M = \{(x_1, c_1), (x_2, c_2), \dots, (x_M, c_M)\}$  un **conjunt de test** de  $M$  mostres independents de les  $N$  d'entrenament.

Anomenem estimador **holdout** de  $\varepsilon_N$  a:

$$\hat{\varepsilon}_{N,M} = \frac{1}{M} \sum_{m=1}^M [c_N(x_m) \neq c_m] = \frac{\text{nombre d'errors}}{M}$$

Aproxima bé  $\varepsilon_N$  quan  $M$  és gran, però **“desaprofita” mostres**.

**Exemple:**  $S_M = \{((0, 0)^t, 1), ((0, 1)^t, 1), ((1, 0)^t, 2)\} \rightarrow \hat{\varepsilon}_{N,M} = \frac{1}{3}$   
(per al problema i classificador exemple)

# Interval de confiança al 95%

Si  $\text{Var}(\varepsilon_N)$  és menyspreable i  $M$  és gran, podem assumir que:

$$\hat{\varepsilon}_{N,M} \sim \mathcal{N} \left( E(\varepsilon_N), \frac{E(\varepsilon_N)(1 - E(\varepsilon_N))}{M} \right)$$

i podem construir un *interval de confiança al 95%* per a  $\varepsilon_N$ ,

$$P(\varepsilon_N \in I) = 0.95 \quad \text{amb} \quad I = \left[ \hat{\varepsilon}_{N,M} \pm 1.96 \sqrt{\frac{\hat{\varepsilon}_{N,M}(1 - \hat{\varepsilon}_{N,M})}{M}} \right]$$

**Exemple:**  $M = 2000$ ,  $\hat{\varepsilon}_{N,M} = 0.05$

$$I = \left[ 0.05 \pm 1.96 \sqrt{\frac{0.05 \cdot 0.95}{2000}} \right] = [0.05 \pm 0.01] = [4\%, 6\%]$$